OpenMP

Metodología de la Programación Paralela Jesús Sánchez Cuadrado (jesusc@um.es) Curso 2019/20

Programación en memoria compartida

- El programa se ve como una colección de elementos de proceso (procesos o hilos) accediendo a una zona central de variables compartidas.
- Más de un elemento podría acceder a la misma zona compartida en el mismo instante produciendo resultados impredecibles.
- Los lenguajes proporcionan primitivas para resolver estos problemas de exclusión mutua (secciones críticas, constructores secuenciales, llaves, semáforos...)

OpenMP

- MP = Multi-Processing
- Especificación disponible
 - https://www.openmp.org/

- Decisiones de diseño
 - Aumentar un lenguaje estándar con constructores paralelos
 - Declarativo
 - Portable
 - Crear programas paralelos de manera incremental

OpenMP vs. Librerías de hilos

OpenMP

- Paralelismo implícito
- Requiere soporte del compilador
- Abstrae de los detalles de bajo nivel

Pthreads

- Paralelismo explícito
- Librería externa
- Detalles de implementación

OpenMP

• Basado en directivas del compilador

#pragma omp [directiva]

Directiva parallel

- Se crea un grupo de threads. El que los pone en marcha actúa de maestro.
- Hay barrera implícita al final de la región.

• Con cláusula if se evalúa su expresión y si da valor distinto de cero se crean los threads, si es cero se hace en secuencial.

• El número de threads a crear se obtiene por variables de entorno, llamadas a librería o con la cláusula num threads.

```
#pragma omp parallel [clausulas]
{
    /* Código paralelo */
}
```

```
int fork = 0;
#pragma omp parallel if (fork)
{ ... }
```

Conceptos

- Team (equipo)
 - Un equipo es un conjunto de hilos que se ejecutan concurrentemente
 - Al principio, el equipo tiene un solo hilo
 - La directiva parallel crea un nuevo conjunto de hilos, que están activos hasta que acabe el bloque
 - La directiva for divide el trabajo entre los hilos el equipo actual.
 - parallel for es una combinación de las dos directivas
 - Siempre hace falta la directiva parallel para ejecutar en paralelo

Directiva parallel

```
#include <stdio.h>
int main(void) {
                                                         Hilo 0
                                                                 Hello
  printf("Hello\n");
  #pragma omp parallel
                                                        fork
                                                      Hilo 1
                                                              Hilo 2
    // El bloque se ejecuta en paralelo
    printf("world!\n");
                                                     world!
                                                             world!
                                                      Hilo 3
                                                              Hilo 4
                                                     world!
                                                             world!
  return 0;
                                                         Hilo 0
```

Directiva parallel

- Cuando dentro de una región hay otro constructor paralelo (anidamiento) cada esclavo crea otro grupo de threads esclavos de los que es el maestro.
- Cláusulas (private, firstprivate, default, shared, copyin y reduction) para indicar la forma en que se accede a las variables.
- Con cláusula if se evalúa su expresión y si da valor distinto de cero se crean los threads, si es cero se hace en secuencial.
- El número de threads a crear se obtiene por variables de entorno, llamadas a librería o con la cláusula num threads .
- Hay barrera implícita al final de la región.

Compilación de programas OpenMP

- Compilación con un compilador C/C++ y la opción de OpenMP:
 - \$ gcc -O3 programa.c -fopenmp
 - \$ icc -O3 programa.c -openmp
 - o -qopenmp en versiones recientes de icc
- Una vez compilado se ejecuta como cualquier otro programa.
- ¿Cuántos threads se ponen en marcha?
 - Por defecto el número de cores.
 - Se puede cambiar con variable de entorno o función de librería.

Establecer el número de hilos

• Utilizando una variable de entorno

```
$ OMP_NUM_THREADS=4 ./helloworld
```

Utilizando la función omp_set_num_threads

• Utilizando la opción num_threads de la directiva parallel

- Las iteraciones se ejecutan en paralelo por threads que ya existen (creados antes con parallel).
- La parte de inicialización del for debe ser una asignación.
- La parte de incremento debe ser una suma o resta.
- La parte de evaluación es la comparación de una variable entera sin signo, utilizando un comparador mayor o menor (puede incluir igual).
- Los valores que aparecen en las tres partes del for deben ser enteros.
- Hay barrera al final a no ser que se utilice la cláusula nowait.
- Cláusulas (private, firstprivate, lastprivate y reduction) para indicar la forma en que se accede a las variables.

```
#define SIZE 360

double sin_table[SIZE];

#pragma omp parallel for
for(int i = 0; i < SIZE; i++)
{
    sin_table[i] = sin(2 * M_PI * i / SIZE);
}</pre>
```

Compilación

Thread local

```
int this_thread = omp_get_thread_num();
int num_threads = omp_get_num_threads();
int my_start = (this_thread ) * SIZE / num_threads;
int my_end = (this_thread+1) * SIZE / num_threads;
for(int i=my_start; i<my_end; ++n)
    sin_table[i] = sin(2 * M_PI * i / SIZE);</pre>
```

- Limitaciones
 - El compilador sólo puede paralelizar bucles en forma canónica

¿Es posible imitar un parallel for solo con una región paralela?

- La variable índice (index) debe ser de tipo entero o puntero
- Las expresiones start, end, e incr deben ser del tipo compatible (ej., index es un puntero, incr debe ser un entero)
- Los valores de start, end e incr no pueden cambiar durante la ejecución del bucle
- La variable index sólo puede cambiarse a través de la operación de incremento de la sentencia for

Ámbito de las variables

Variable privada

- Cada hilo tiene su propia "versión" de la variable
- Lecturas y escrituras son locales al hilo
- Modificador **private(var)** o declaradas dentro de parallel

```
int v_shared = 5;
#pragma omp parallel
{
   int local = ...;
}
```

Variable compartida

- Puede ser accedida por todos los hilos
- Requerirá sección crítica cuando hay escrituras
- Modificador shared(var) o declaradas fuera de parallel

```
int v = 5;
#pragma omp parallel \
    private(local) shared(v)
{
    int local = ...;
}
```

```
#pragma omp parallel for
for(int i = 0; i < 10; i++)</pre>
  /* Código paralelo */
int i;
#pragma omp parallel for private(i)
for(i = 0; i < 10; i++)
  /* Código paralelo */
```

i es local bucle

i no es local al bucle pero OpenMP la hace privada por defecto

No es obligatorio **private** pero es conveniente

```
#pragma omp parallel for private(temp)
for(i=0; i < N; i++){
  for (j=0; j < M; j++){
    temp = b[i] * c[j];
    a[i][j] = temp * temp + d[i];
}
</pre>
```

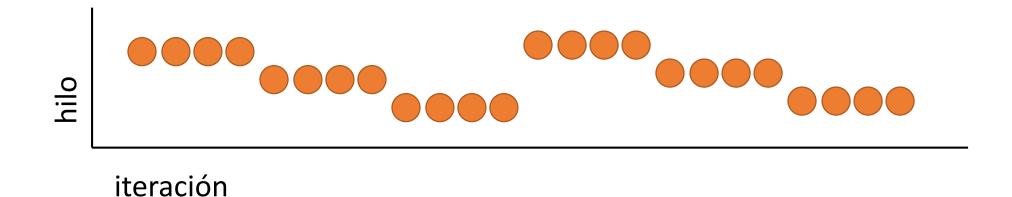
¿Por qué es incorrecto?

Manejo de variables

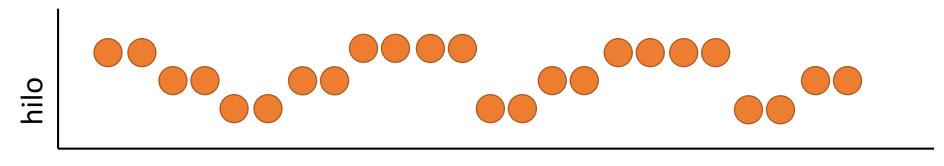
- private(lista)
 - privadas a los threads, no se inicializan antes de entrar y no se guarda su valor al salir.
- firstprivate(lista)
 - privadas a los threads, se inicializan al entrar con el valor que tuviera la variable correspondiente.
- lastprivate(lista)
 - privadas a los threads, al salir quedan con el valor de la última iteración o sección.
- shared(lista)
 - compartidas por todos los threads.
- default(shared none)
 - indica cómo serán las variables por defecto.
- reduction(operador:lista)
 - se obtienen por la aplicación del operador.
- copyin(lista)
 - para asignar el valor de la variable en el master a variables locales privadas a los threads al empezar la región paralela.

- La cláusula **schedule** indica la forma en que se dividen las iteraciones del for entre los threads.
 - schedule(static,tamaño) las iteraciones se dividen según el tamaño, y la asignación se hace estáticamente a los threads. Si no se indica el tamaño se divide por igual entre los threads.
 - schedule(dynamic, tamaño) las iteraciones se dividen según el tamaño y se asignan a los threads dinámicamente cuando van acabando su trabajo.
 - schedule(guided, tamaño) las iteraciones se asignan dinámicamente a los threads pero con tamaños decrecientes.
 - schedule(runtime) deja la decisión para el tiempo de ejecución, y se obtienen de la variable de entorno OMP SCHEDULE.

- schedule(static, 4)
 - **Ejemplo**. Bucle **for** con 24 iteraciones dividido entre 3 hilos
 - El trabajo (24 iteraciones) se divide antes de comenzar la ejecución entre los 3 hilos
 - Aunque un hilo termine antes no hará trabajo que no le haya sido asignado de antemano



- schedule(dynamic, 2)
 - **Ejemplo**. Bucle **for** con 24 iteraciones, 3 hilos
 - Cada hilo va pidiendo trabajo cuando está ocioso.
 - La unidad de trabajo es 2 iteraciones.
 - Apropiado cuando cada iteración puede tener un coste de ejecución diferente
 - Hay mayor "overhead" porque la asignación de trabajo es dinámica

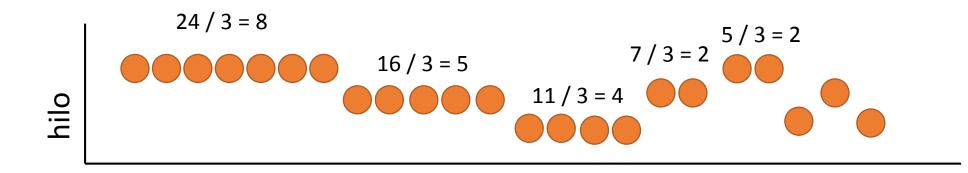


iteración

```
int sum = 0.0;
#pragma omp parallel for
for(int i = 0; i <= n; i++) {
    #pragma omp critical
    sum += f(i)
}</pre>
```

```
¿Qué sucede si f(i) tarda más cuando i es mayor?
```

- schedule(guided, 2)
 - **Ejemplo**. Bucle **for** con 24 iteraciones, 3 hilos
 - Tamaño de cada trabajo es proporcional al número de iteraciones sin asignar dividido por el número de hilos: iteraciones sin asignar / número de hilos



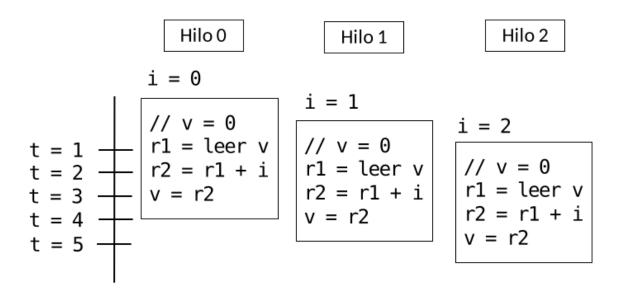
iteración

- Para una buena discusión:
 - https://stackoverflow.com/questions/10850155/whats-the-difference-between-static-and-dynamic-schedule-in-openmp
 - https://stackoverflow.com/questions/42970700/openmp-dynamic-vs-guided-scheduling
 - http://jakascorner.com/blog/2016/06/omp-for-scheduling.html

 Condición carrera. Dos o más hilos acceden a un dato compartido y pueden cambiarlo al mismo tiempo dando lugar a resultados incorrectos.

```
int v = 0;

#pragma omp parallel for
for(int i = 0; i < n; i++) {
   if (i % 2 == 0) {
     v += i;
   }
}</pre>
```



- *pragma omp critical [(nombre)]
- Establece una región de exclusión de mutua
- Sólo un bloque puede estar ejecutándola a la vez
- El nombre es opcional, pero permite que haya más de una región crítica por programa
 - Dos regiones críticas con nombres diferentes se podrán ejecutar a la vez

*pragma omp critical [(nombre)]

• ¿Es eficiente?

```
int v = 0;

#pragma omp parallel
{
    #pragma omp critical
    {
       total = calc(omp_get_thread_num());
       v = v + total;
    }
}
```

- #pragma omp atomic
- Establece una región de exclusión de mutua para actualizar una asignación que tenga la siguiente forma:

```
x <op> = <expresión>
x++;
++x;
+--;
---x;
<op> = 
+, *, -, /, &, ^, |, <<, >>
```

• El compilador utilizará instrucciones CAS para hacerla muy eficiente

• #pragma omp atomic

```
int v = 0;

#pragma omp parallel for
for(int i = 0; i < n; i++) {
   if (i % 2 == 0) {
        #pragma omp atomic
        v += i;
    }
}</pre>
```

ejemplo_lock.c

- Candados (lock)
 - Es el mecanismo de sincronización más flexible
- void omp_init_lock(omp_lock_t *lock);
 - Para inicializar una llave. Una llave se inicializa como no bloqueada.
- void omp_init_destroy(omp_lock_t *lock);
 - Para destruir una llave.
- void omp_set_lock(omp_lock_t *lock);
 - Para pedir una llave.
- void omp_unset_lock(omp_lock_t *lock);
 - Para soltar una llave.
- int omp_test_lock(omp_lock_t *lock);
 - Intenta pedir una llave pero no se bloquea.

Operador de reducción

*pragma omp parallel private(i) reduction(+:x)

- Varios hilos calculan un valor que necesita ser combinado con los valores de los otros hilos.
- Se puede utilizar una directiva critical para evitar condiciones de carrera
- La clausula reduction hace el trabajo:
 - OpenMP crea una copia local de la variable reducida en cada hilo
 - Cada hilo va calculando su propio valor local
 - Al final de la ejecución (en el join) los valores se combinan según el operador

Operador de reducción

• Ejemplo, cálculo de PI

```
int n = 50;
int i;
double PI25DT = 3.141592653589793238462643;
double pi, h, sum, x;
// Inicializa el número de intervalos a n
h = 1.0 / (double) n;
sum = 0.0;
// La variable pi es una variable de reducción mediante suma
#pragma omp parallel for reduction(+:pi) private(x, i)
for (i = 1; i <= n; i ++) {
   x = h * ((double)i - 0.5);
   pi += f(x);
pi = 4. * h * pi;
```

- Directiva sections y section
- Cada sección se ejecuta por un thread
- Hay barrera al final a no ser que se utilice la cláusula nowait

```
#pragma omp sections [clausulas]
{
    [#pragma omp section]
    bloque1
    [#pragma omp section]
    bloque2
}
```

Sections

- Ejecuta un número fijo de hilos
- Cada sección con un código diferente

```
#define N 1000
void main (){
   int i; float a[N], b[N], c[N];
   for (i=0; i < N; i++) a[i] = b[i] = ...;
   #pragma omp parallel sections default(none) shared(a,b,c)
   {
        #pragma omp section
        { for (int i=0; i < N/2; i++) c[i] = a[i] + b[i]; }
        #pragma omp section
        { for (int i=N/2; i < N; i++) c[i] = a[i] + b[i]; }
}</pre>
```

¿Qué hace este código?

Opción nowait

- Admitida en sections y for
- Evita que los hilos se sincronicen al final de la ejecución de esas claúsulas

```
#pragma omp parallel
  #pragma omp for nowait
  for (i=1; i < n; i++) {
    b[i] = (a[i] + a[i-1]) / 2.0;
  #pragma omp for nowait
  for (i=1; i < n; i++) {
     y[i] = sqrt(z[i]);
```

Constructores combinados

• Forma abreviada de directiva parallel con una única directiva for o sections, de las que admite sus cláusulas menos la nowait.

```
#pragma omp parallel for [clausulas]
bucle for
```

#pragma omp parallel sections [clausulas]

¿Por qué nowait no se permite?

Ejecución secuencial

*pragma omp single [clausulas]

ejemplo_single.c

- El bloque se ejecuta por único hilo
- Hay una barrera al final a no ser que se incluya la claúsula nowait
- #pragma omp master

ejemplo_master.c

- El bloque se ejecuta únicamente por el hilo maestro
- No hay sincronización ni al entrar ni al salir
- #pragma omp ordered

ejemplo_ordered.c

• El bloque se ejecuta en el orden en que se ejecutaría en secuencial

single vs. critical

- single
 - El código debe ejecutarlo un único hilo, el resto no lo ejecutan
- critical
 - El código lo ejecuta un único hilo en cierto instante de tiempo, pero todos los hilos lo ejecutarán (si su lógica lo permite)

```
int a=0, b=0;
#pragma omp parallel num_threads(4)
{
    #pragma omp single
    a++;
    #pragma omp critical
    b++;
}
```

¿Cuánto valen a y b al final del bloque paralelo?

ejemplo_barrier.c

Barreras

- Sincronización explícita de los threads
 - Construcción barrier
- Sincronización implícita al final la sección parallel.

```
#pragma omp barrier
// ... código ...

// Barrera según cierta condición
if (x == 0) {
    #pragma omp barrier
}
```

Barreras

- Ejemplo
- Sincronizar los hilos en cada iteración de un bucle

```
int v[4] = \dots
#pragma omp parallel num threads(4)
  int tid = omp get thread num();
  // Cada hilo ejecuta 20 iteraciones del bucle
  for(int i = 0; i < 20; i++) {</pre>
    int valor = calculo(x[mytid]);
    #pragma omp barrier
    // Esperar que todos los hilos hagan el calculo
    // Tomar el valor del vecino
    x[tid] = x[(tid+1) % 4] + 1;
```

Funciones de librería

- void omp_set_num_threads(int num_threads);
 - Establece el número de threads a usar en la siguiente región paralela.
- int omp_get_num_threads(void);
 - Obtiene el número de threads que se están usando en una región paralela.
- int omp_get_max_threads(void);
 - Obtiene la máxima cantidad posible de threads.
- int omp_get_thread_num(void);
 - Devuelve el número del thread.
- int omp_get_num_procs(void);
 - Devuelve el máximo número de procesadores que se pueden asignar al programa.
- int omp_in_parallel(void);
 - Devuelve valor distinto de cero si se ejecuta dentro de una región paralela.

Funciones de librería

- int omp_set_dynamic(void);
 - Permite poner o quitar el que el número de threads se pueda ajustar dinámicamente en las regiones paralelas.
- int omp_get_dynamic(void);
 - Devuelve un valor distinto de cero si está permitido el ajuste dinámico del número de threads.
- int omp_set_nested(int);
 - Para permitir o desautorizar el paralelismo anidado
- int omp_get_nested(void);
 - Devuelve un valor distinto de cero si está permitido el paralelismo anidado

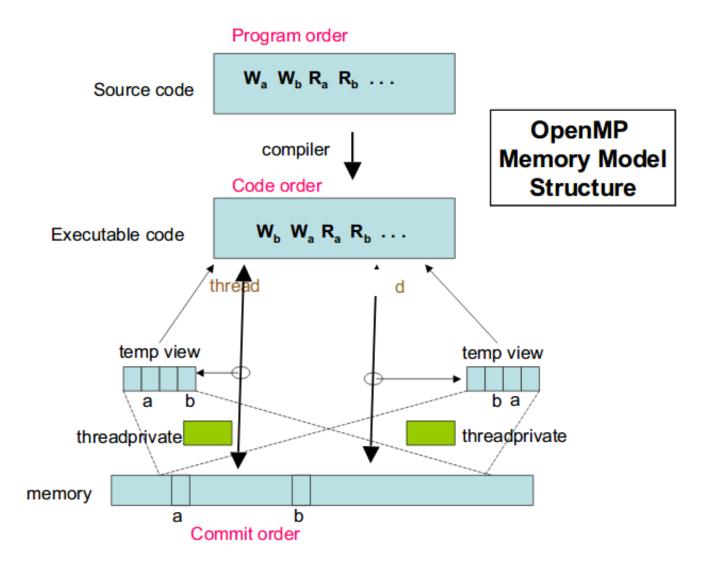
- Compilador y procesador puede reordenar
- La asignación está temporalmente en un registro

Ejemplo

- Pero también, c = 0, d = 0
 - Si los hilos no "ven" la actualización de a y b

```
a = b = c = d = 0;
#pragma omp sections
   #pragma omp sections
   { a = 1; c = b; }
   #pragma omp sections
   { b = 1; d = a; }
```

Modelo de memoria de OpenMP



- El compilador puede reordenar las instrucciones
- Un hilo ejecutándose en un core puede mantener las variables en registros (no hacer commit a memoria)
- El resto de hilos leerán de su cache local o de memoria principal y no verán el valor

- #pragma omp flush [lista variables]
 - Asegura que las variables que aparecen en la lista quedan actualizadas para todos los threads.

- En OpenMP se hace flush implícito en ciertas situaciones:
- Barreras barrier
- A la entrada y la salida de:
 - parallel, parallel worksharing, critical, regiones ordered
- A la entrada ya salida de atomic
- A la salida de regiones worksharing (a no ser que se indique nowait)
- En omp_set_lock, omp_set_nest_lock, omp_set_nest_lock, omp_unset_nest_lock
- En omp_test_lock, omp_test_nest_lock, si se adquiere el candado

• Directivas en las que aparece implícitamente una directiva flush

Directiva	Momento de flush
barrier	Al ejecutarse
critical	Al entrar y al salir
ordered	Al entrar y al salir
parallel	Al salir
for	Al salir
sections	Al salir
single	Al salir

- Para comunicar el valor de una variable compartida de un hilo a otro, hay que realizar los siguientes pasos, en este orden:
 - 1. Escribir en la variable en el hilo A
 - 2. Hacer flush (implícito o explícito) de la variable en el hilo A
 - 3. Hacer flush (implícito o explícito) de la variable en el hilo B
 - 4. Leer la variable en el hilo B

- Productor / Consumidor
- ¿Cómo "notificar" al otro hilo que el resultado está listo?
 - A través de la variable flag
 - Necesitamos flush

```
int N = 10000;
double *A = (double *) malloc(N*sizeof(double));
int sum;
#pragma omp parallel sections
  // productor
  #pragma omp section
    fill rand(A, N);
    flag = 1;
  // consumidor
  #pragma omp section
    while (flag==0) { }
    sum = sum_array(A, N);
```

```
#pragma omp parallel sections
 #pragma omp section // productor
   fill rand(A, N);
   #pragma omp flush // Asegura que flag sera escrito despues de fill_rand
    flag = 1;
   #pragma omp flush (flag) // Asegura que flag es escrito en memoria
  #pragma omp section // consumidor
    // Asegura que el flag es leído de memoria
    #pragma omp flush (flag)
   while (flag==0) {
     #pragma omp flush (flag)
    #pragma omp flush // Evita reordenar la suma con el bucle
    sum = sum array(A, N);
```

- Modificador volatile
 - Indica que una variable siempre debe escribirse en memoria principal
 - Hay un flush() implícito antes de cada lectura y después de cada escritura
 - Impide optimizaciones

Búsqueda en array

```
#pragma omp parallel private(i, id, p, load, begin, end)
  p = omp_get_num_threads();
  id = omp_get_thread_num();
  load = N/p; begin = id*load; end = begin+load;
  for (i = begin; ((i<end) && keepon); i++) {</pre>
    if (a[i] == x) {
      keepon = 0;
      position = i;
                                                  ¿Hay algún
                                                  problema?
```

Modelos de memoria

- https://stackoverflow.com/questions/12429818/does-explicit-lock-automatically-provide-memory-visibility
- http://tutorials.jenkov.com/java-concurrency/java-memory-model.html
- https://medium.com/@pablocastelnovo/variables-vol%C3%A1tiles-en-java-f5ae078bf8b9
- https://stackoverflow.com/questions/41612143/is-openmp-atomic-write-needed-if-other-threads-read-only-the-shared-data

- Memorias cache
 - Cache hit: cuando la CPU necesita un valor de memoria y el valor está en la cache, lo puede recuperar rápidamente
 - Cache miss: Cuando la CPU necesita un valor pero no está en la cache y debe ir a buscarlo a memoria
 - Los memoria cache se organiza en líneas o bloques, típicamente de 64 bytes

- Coherencia espacial
 - Si el programa usa una dirección de memoria ahora, posiblemente necesita pronto los valores de las direcciones de memoria cercanas
- Coherencia temporal
 - Si el programa está usando una dirección de memoria ahora, posiblemente la volverá a utilizar pronto

Si se cumplen estas reglas => Cache hit ++ Si no => Cache miss ++

- cache-miss-row.c
- cache-miss-col.c

- ¿Cuál va más rápido?
 - Complejidad igual O (n²)

```
double array[NUM];

for( int i = 0; i < NUM; i++ ){
   for( int j = 0; j < NUM; j++ ){
      sum += array[ i ][ j ];
      // acceso por filas
   }
}</pre>
```

```
double array[NUM];

for( int i = 0; i < NUM; i++ ){
    for( int j = 0; j < NUM; j++ ){
        sum += array[ j ][ i ];
        // acceso por columnas
    }
    }
}</pre>
```

• Herramientas para analizar fallos de cache

```
$ valgrind --tool=cachegrind ./mi_programa
```

\$ sudo perf stat -d ./mi_programa

^{*} http://www.brendangregg.com/perf.html

- Cachegrind
 - Simula cómo interacciona el programa con la memoria cache y con el predictor de saltos
 - Asume una arquitectura con dos niveles de cache, L1 y LL.
 - Si la arquitectura tiene más niveles sólo se analiza el último
 - Por desgracia no funciona bien con programas multi-hilo
 - Usar perf
 - I => Instruction
 - D => Data

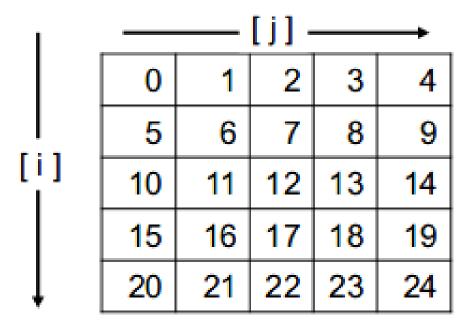
cache-miss-row.c

```
==23156== D refs: 700,133,994 (600,101,603 rd + 100,032,391 wr)
==23156== D1 misses: 6,254,292 (6,253,488 rd + 804 wr)
==23156== LLd misses: 6,253,340 (6,252,605 rd + 735 wr)
==23156== D1 miss rate: 0.9% (1.0% + 0.0%)
==23156== LLd miss rate: 0.9% (1.0% + 0.0%)
```

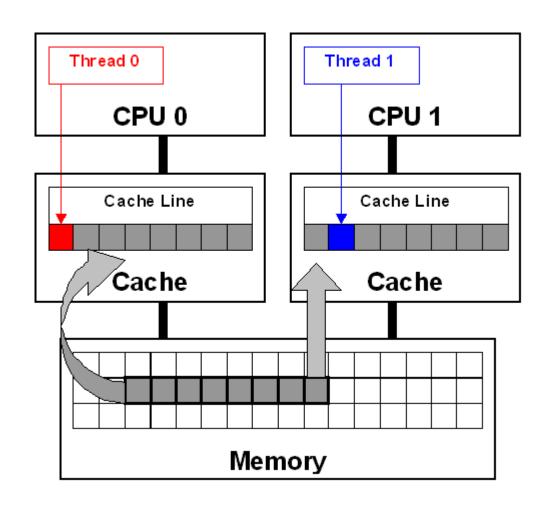
cache-miss-col.c

```
==26047== D refs: 700,133,998 (600,101,605 rd + 100,032,393 wr)
==26047== D1 misses: 100,004,290 (100,003,482 rd + 808 wr)
==26047== LLd misses: 6,263,341 (6,262,604 rd + 737 wr)
==26047== D1 miss rate: 14.3% (16.7% + 0.0%)
==26047== LLd miss rate: 0.9% (1.0% + 0.0%)
```

- Al recorrer por columnas estamos "sacando" de la memoria cache líneas que vamos a necesitar en otras iteraciones
- Es mejor recorrer en la dirección de las líneas de cache



- El problema es aún peor cuando tenemos varios hilos
- Al escribir en una posición de memoria se invalida la línea entera
- Se puede producir un efecto pingpong



Errores comunes

Ver presentación adicional

Ejercicio

- Buscar en un array
 - Versión ineficiente, ¿por qué?

```
#pragma omp parallel for
for ( i = 0 ; i < N; ++i ) {
    #pragma omp critical
    {
        if (arr[i] > max )
            max = arr[i] ;
    }
}
```

Versión algo mejor, ¿por qué?

Ejercicio

- Búsqueda en array
 - Versión propuesta para emular reduce
 - ¿Es mejor?
 - ¿Es correcta?

```
#pragma omp parallel
  int priv max;
  #pragma omp for
  for (i = 0; i < N; ++i) {
    if (arr[i] > priv_max) {
      priv_max = arr[i];
    #pragma omp flush(max)
    if (privmax > max) {
       #pragma omp critical
       if (priv_max > max )
         max = priv_max;
```

- Se introducen en OpenMP 3.0
- OpenMP cambia de "thread-centric" a "task-centric".
- Para expresar paralelismo irregular y no estructurado.
- Para paralelizar bucles while . Por ejemplo, recorrido de una lista de punteros de longitud no conocida.

```
p = list_head();
while (!list_end(p)) {
  procesar( p );
  p = list_next(p);
}
```

- Ejemplo
 - Recorrido de una lista
 - La directa single asegura que un solo hilo se encarga de generar las tareas.

```
#pragma omp parallel
#pragma omp single
  while (!list_tail(p)) {
    p = list_next(p);
    #pragma omp task
    procesar(p);
  #pragma omp taskwait
```

- Hay una cola por equipo (privada, manejada por OpenMP)
- Un hilo (ej., master) comienza a generar tareas
- Las tareas pueden generar tareas recursivamente
- El sistema organiza pone las tareas en hilos automáticamente

- Dos tipos de tareas:
 - **Tied task**: ligada a un thread fijo que la ejecuta. Puede tener pausas o hacer otra cosa, pero ese thread acaba la tarea.
 - Untied task: a cualquier thread del team el scheduler le puede asignar una untied task que esté suspendida en ese momento

- *pragma omp task [clausulas]bloque
 - if (scalar expression)
 - untied
 - default(shared|none) , private , firstprivate y shared
- #pragma omp taskwait
 - La tarea actual se suspende hasta la finalización de sus tareas hijas.
 - Un conjunto de tareas será forzado a completarse:
 - En una barrera implícita de threads.
 - En una barrera explícita de threads (#pragma omp barrier).
 - En una barrera de tareas (#pragma omp taskwait).

• Secuencia de Fibonacci

```
int fib(int n) {
   if (n < 2) return n;
   int x = fib(n - 1);
   int y = fib(n - 2);
   return x + y;
}</pre>
```

```
#pragma omp parallel
#pragma omp single
   fib(10000);
int fib(int n) {
   if (n < 2) return n;
   #pragma omp task shared(x)
   int x = fib(n - 1);
   #pragma omp task shared(y)
   int y = fib(n - 2);
   #pragma omp taskwait
   return x + y;
```

^{* &}lt;a href="https://www.youtube.com/watch?v=Wx4eQQihP61">https://www.youtube.com/watch?v=Wx4eQQihP61

Medir tiempos

```
double inicio, fin;
inicio = omp_get_wtime();
/* código */
fin = omp_get_wtime(); + Preciso
printf("Tiempo: %2.f", fin - inicio);
```

```
time ./programa + Fácil
```

Mooshak (calisto.inf.um.es, quad-core) + Speed-up

Código portable en OpenMP

```
#if defined (_OPENMP)
#include <omp.h>
#endif
int main() {
  int iam = 0, np = 1;
  #pragma omp parallel private(iam,np)
#if defined ( OPENMP)
    np = omp_get_num_threads();
    iam = omp get thread num();
#endif
    printf("Hello from thread %d out of %d \n", iam, np);
```

Experimento rápido

```
for t in 1 2 4 8 12 16; do
   OMP_NUM_THREADS=$t ./programa
done
```

Variables de entorno

- OMP_WAIT_POLICY=active
 - Los hilos hacen esperan active (spin) en lugar de dormir (sleep)
- OMP_DYNAMIC=false
 - Obliga al runtime a usar exactamente tantos hilos como los que se indiquen
- OMP_PROC_BIND=true
 - Evita que los hilos puedan moverse entre los cores (thread/core affinity)

Bibliografía

- Diapositivas basadas en:
 - Curso de Domingo Giménez Cánovas
 - http://dis.um.es/~domingo/mpp.html
 - An Introduction to Parallel Programming, Peter Pacheco
 - Disponible en el Aula Virtual
 - Introducción a la Programación Paralela, Domingo Giménez Cánovas
 - Disponible en la biblioteca
 - Ejemplos y foros de Internet
 - Probar búsquedas como "OpenMP examples"